Data Cleaning & Preprocessing

2.1 Formatting Column Names

```
# Membersihkan nama kolom
print(f'Original column names: {df.columns.tolist()}')

def clean_column_names(df):
    """
    Membersihkan nama kolom dari spasi dan mengubah menjadi lowercase
    """
    df.columns = df.columns.str.lower().str.replace(' ', '')
    return df

df = clean_column_names(df)
print(f'Cleaned column names: {df.columns.tolist()}')
```

Penjelasan:

- `str.lower()` : Mengubah semua nama kolom menjadi huruf kecil
- `str.replace(' ', '')` : Menghapus spasi dalam nama kolom
- **Tujuan**: Standardisasi nama kolom agar konsisten dan mudah diakses

output

```
original column names: ['InvoiceNo', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Uni
cleaned column names: ['invoiceno', 'stockcode', 'description', 'quantity', 'invoicedate', 'unit
```

2.2 Check Missing Value

```
# Menghitung missing value
missing_value = df.isnull().sum()
missing_percentage = (df.isnull().sum()/len(df)) * 100

# Membuat DataFrame untuk analisis missing value
missing_df = pd.DataFrame({
    'Kolom': missing_value.index,
    'Jumlah Missing Value': missing_value.values,
    'Persentase Missing Value': (missing_value.values / len(df)) * 100
})

# Filter dan sort kolom yang memiliki missing value
missing_df = missing_df[missing_df['Jumlah Missing Value'] > 0].sort_values('Jumlah Missing Valu

print(missing_df)
```

Penjelasan:

- `df.isnull().sum()` : Menghitung jumlah nilai null per kolom
- Membuat DataFrame terstruktur untuk memvisualisasikan missing value
- **Output**: Tabel yang menampilkan kolom dengan missing value, jumlah, dan persentasenya

output persentase missing value

```
Kolom  Jumlah Missing Value  Persentase Missing Value
6   customerid               135080                24.926694
2  description                1454                 0.268311
```

2.3 Handle Missing Values

2.3.1 Handle Missing Value pada CustomerID

```
if 'customerid' in df.columns:
    # Mengecek pola missing value
    print(f'Jumlah missing value di kolom customerid: {df["customerid"].isnull().sum():,}')

    # Hapus baris tanpa customerid (untuk analisis pelanggan)
    df_with_customerid = df.dropna(subset=['customerid']).copy()

    # Mengisi missing value dengan 'unknown' (untuk analisis produk)
    df['customerid'] = df['customerid'].fillna('unknown')
```

Strategi:

- **Dual approach**: Membuat 2 versi dataset
  - `df_with_customerid` : Untuk analisis yang berfokus pada pelanggan
  - `df` : Untuk analisis produk (customerid diisi 'unknown')

output(untuk analisis produk dan analisis pelanggan)

```
jumlah missing value di kolom customerid: 135,080
 data kolom customerid untuk analisis produk:
 0         17850.0
1         17850.0
2         17850.0
3         17850.0
4         17850.0
           ...
541904    12680.0
541905    12680.0
541906    12680.0
541907    12680.0
541908    12680.0
Name: customerid, Length: 541909, dtype: object
 data kolom customerid untuk analisis pelanggan:
 0         17850.0
1         17850.0
2         17850.0
3         17850.0
4         17850.0
           ...
541904    12680.0
541905    12680.0
541906    12680.0
541907    12680.0
541908    12680.0
Name: customerid, Length: 406829, dtype: float64
```

2.3.2 Handle Missing Value pada Description

```
if 'description' in df.columns:
    print(f'Jumlah missing value di kolom description: {df["description"].isnull().sum():,}')

    # Mengisi missing value dengan 'no description'
    df['description'] = df['description'].fillna('no description')

    print(f'Jumlah missing value setelah handling: {df["description"].isnull().sum():,}')
```

Strategi:

- Mengisi dengan placeholder `'no description'` karena kolom ini penting untuk analisis produk

output kolom deskripsi

```
jumlah missing value di kolom description: 1,454
jumlah missing value di kolom description setelah handling: 0
```

2.3.3 Handle Missing Value pada Kolom Numerik

```
# Identifikasi kolom numerik
numeric_columns = df.select_dtypes(include=['int64', 'float64']).columns.tolist()

# Mengisi missing value berdasarkan distribusi data
for col in numeric_columns:
    missing_count = df[col].isnull().sum()

    if missing_count > 0:
        # Menghitung skewness
        skewness = df[col].skew()

        if abs(skewness) > 0.5:
            # Distribusi tidak normal → gunakan Median
            fill_value = df[col].median()
            strategy = 'Median'
        else:
            # Distribusi normal → gunakan Mean
            fill_value = df[col].mean()
            strategy = 'Mean'

        # Mengisi missing value
        df[col] = df[col].fillna(fill_value)
        print(f"Kolom '{col}': {missing_count} missing value diisi dengan {strategy} (skewness:
```

Strategi Statistik:

- **Skewness > 0.5**: Data tidak normal → gunakan **Median** (lebih robust terhadap outliers)
- **Skewness ≤ 0.5**: Data normal → gunakan **Mean**

output kolom numerik

```
['quantity', 'unitprice']
Kolom quantity tidak memiliki missing value
Kolom unitprice tidak memiliki missing value
```

2.3.4 Handle Missing Value pada Kolom Kategorikal

```
# Identifikasi kolom kategorikal
categorical_columns = df.select_dtypes(include=['object']).columns.tolist()

# Mengisi missing value dengan modus (nilai terbanyak)
for col in categorical_columns:
    missing_count_categoric = df[col].isnull().sum()

    if missing_count_categoric > 0:
        mode_value = df[col].mode()[0]
        df[col] = df[col].fillna(mode_value)
        print(f'Kolom {col}: {missing_count_categoric} missing value diisi dengan modus {mode_va
```

Strategi:

- Gunakan **Modus** (nilai yang paling sering muncul) untuk data kategorikal

output kolom kategorik

```
['invoiceno', 'stockcode', 'description', 'invoicedate', 'customerid', 'country']
Kolom invoiceno tidak memiliki missing value
Kolom stockcode tidak memiliki missing value
Kolom description tidak memiliki missing value
Kolom invoicedate tidak memiliki missing value
Kolom customerid tidak memiliki missing value
Kolom country tidak memiliki missing value
```

2.4 Menghandle Duplicate

```
# Mengecek duplikat
duplicates = df.duplicated().sum()
print(f'Jumlah baris duplikat: {duplicates:,}')

# Melihat contoh duplikat
if duplicates:
    print('Contoh baris duplikat:')
    print(df[df.duplicated(keep=False)].head(10))

# Menghapus duplikat
df_before = len(df)
df = df.drop_duplicates()
df_after = len(df)

print(f'Jumlah data sebelum drop duplicate: {df_before}')
print(f'Jumlah data setelah drop duplicate: {df_after}')
```

Penjelasan:

- `duplicated()` : Mendeteksi baris yang identik
- `keep=False` : Menampilkan semua duplikat (termasuk yang pertama)
- `drop_duplicates()` : Menghapus baris duplikat, hanya menyimpan yang pertama

output contoh data yang memiliki nilai duplikat

```
contoh baris duplikat :
    invoiceno stockcode                         description  quantity  \
485    536409     22111       SCOTTIE DOG HOT WATER BOTTLE         1
489    536409     22866      HAND WARMER SCOTTY DOG DESIGN         1
494    536409     21866        UNION JACK FLAG LUGGAGE TAG         1
517    536409     21866        UNION JACK FLAG LUGGAGE TAG         1
521    536409     22900    SET 2 TEA TOWELS I LOVE LONDON          1
527    536409     22866      HAND WARMER SCOTTY DOG DESIGN         1
537    536409     22900    SET 2 TEA TOWELS I LOVE LONDON          1
539    536409     22111       SCOTTIE DOG HOT WATER BOTTLE         1
548    536412     22327  ROUND SNACK BOXES SET OF 4 SKULLS         1
555    536412     22327  ROUND SNACK BOXES SET OF 4 SKULLS         1

         invoicedate  unitprice customerid         country
485  12/1/2010 11:45       4.95    17908.0  United Kingdom
489  12/1/2010 11:45       2.10    17908.0  United Kingdom
494  12/1/2010 11:45       1.25    17908.0  United Kingdom
517  12/1/2010 11:45       1.25    17908.0  United Kingdom
521  12/1/2010 11:45       2.95    17908.0  United Kingdom
527  12/1/2010 11:45       2.10    17908.0  United Kingdom
537  12/1/2010 11:45       2.95    17908.0  United Kingdom
539  12/1/2010 11:45       4.95    17908.0  United Kingdom
548  12/1/2010 11:49       2.95    17920.0  United Kingdom
555  12/1/2010 11:49       2.95    17920.0  United Kingdom

jumlah data sebelum drop duplicate: 541909
jumlah data setelah drop duplicate: 536641
```

2.5 Cleaning Data Values (Text Columns)

```
def clean_text_columns(df):
    """
    Membersihkan nilai dalam kolom text:
    - Menghapus spasi berlebih
    - Mengubah semua huruf menjadi lowercase
    - Strip whitespace
    """
    text_columns = df.select_dtypes(include=['object']).columns

    for col in text_columns:
        # Mengubah huruf menjadi lowercase dan menghapus spasi berlebih
        df[col] = df[col].astype(str).str.strip().str.lower()
        # Ganti multiple spaces dengan single space
        df[col] = df[col].str.replace(r'\s+', ' ', regex=True)

    return df

df = clean_text_columns(df)
print(df.head())
```

Tujuan:

- **Standardisasi teks**: lowercase, hapus spasi berlebih
- **Konsistensi data**: memudahkan analisis dan filtering

output membersihkan nilai dalam kolom

```
invoiceno stockcode                    description  quantity  \
0    536365    85123a  whitehangingheartt-lightholder         6
1    536365     71053               whitemetallantern         6
2    536365    84406b      creamcupidheartscoathanger         8
3    536365    84029g  knitteduniionflaghotwaterbottle         6
4    536365    84029e      redwoollyhottiewhiteheart.         6

     invoicedate  unitprice customerid        country
0  12/1/20108:26        2.55    17850.0  unitedkingdom
1  12/1/20108:26        3.39    17850.0  unitedkingdom
2  12/1/20108:26        2.75    17850.0  unitedkingdom
3  12/1/20108:26        3.39    17850.0  unitedkingdom
4  12/1/20108:26        3.39    17850.0  unitedkingdom
```

2.6 Adjust Data Type

2.6.1 Konversi InvoiceDate ke Datetime

```
if 'invoicedate' in df.columns:
    df['invoicedate'] = pd.to_datetime(df['invoicedate'], format='%m/%d/%Y %H:%M')
    print(df['invoicedate'].dtype)
```

output mengecek tipe data sebelum diubah

```
tipe data setiap kolom sebelum diubah :
invoiceno       object
stockcode       object
description     object
quantity         int64
invoicedate     object
unitprice      float64
customerid      object
country         object
dtype: object
```

2.6.3 Konversi InvoiceDate ke datetime

```
# mengubah tipe data 'invoicedate' menjadi datetime
if 'invoicedate' in df.columns:
    df['invoicedate'] = pd.to_datetime(df['invoicedate'], format = '%m/%d/%Y%H:%M')
    # mengecek tipe data 'invoicedate'
    print(df['invoicedate'].dtype)
```

tipe data InvoiceDate setelah diubah

```
datetime64[ns]
```

2.6.3 Konversi CustomerID ke String

```
if 'customerid' in df.columns:
    df['customerid'] = df['customerid'].astype(str)
    print(df['customerid'].dtype)
```

```
object
```

2.6.4 Memastikan Kolom Numerik Benar

```
numerical_mapping = {
    'quantity': int,
    'unitprice': float
}

for col, dtype in numerical_mapping.items():
    if col in df.columns:
        df[col] = pd.to_numeric(df[col], errors='coerce')
        if dtype == int:
            df[col] = df[col].astype(int)
        print(f'Kolom {col} sudah diubah menjadi {dtype}')

# Memverifikasi tipe data
print("Tipe data setiap kolom:\n", df.dtypes)
```

```
kolom quantity sudah diubah menjadi <class 'int'>
kolom unitprice sudah diubah menjadi <class 'float'>
```

Penjelasan:

- `pd.to_numeric()` : Mengkonversi ke numerik, nilai invalid menjadi NaN
- `errors='coerce'` : Mengubah nilai yang tidak valid menjadi NaN

2.7 Handling Outliers

2.7.1 Fungsi Deteksi Outliers dengan Metode IQR

```
def detect_outliers(df, column):
    """
    Mendeteksi outliers menggunakan metode IQR (Interquartile Range)
    """
    Q1 = df[column].quantile(0.25)  # Kuartil 1 (25%)
    Q3 = df[column].quantile(0.75)  # Kuartil 3 (75%)

    IQR = Q3 - Q1  # Interquartile Range

    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    outliers = df[(df[column] < lower_bound) | (df[column] > upper_bound)]

    return outliers, lower_bound, upper_bound
```

Metode IQR:

- **Q1**: Persentil ke-25
- **Q3**: Persentil ke-75
- **IQR**: Q3 - Q1
- **Outlier**: Nilai < Q1 - 1.5×IQR atau > Q3 + 1.5×IQR

2.7.2 Mengecek Outliers untuk Setiap Kolom Numerik

```
numerical_cols = ['quantity', 'unitprice']

for col in numerical_cols:
    if col in df.columns:
        print(f'Outliers for {col}:')

        outliers, lower_bound, upper_bound = detect_outliers(df, col)
        print(f'Jumlah outliers: {len(outliers)}')
        print(f'Persentase outliers: {len(outliers) / len(df) * 100:.2f}%')
        print(f'Lower bound: {lower_bound:.2f}')
        print(f'Upper bound: {upper_bound:.2f}')
        print(f'Min value: {df[col].min():.2f}')
        print(f'Max value: {df[col].max():.2f}')
```

```
Outliers for quantity:
jumlah outliers: 58501
persentase outliers: 10.90%
lower bound: -12.50
upper bound: 23.50
min value: -80995.00
max value: 80995.00

Outliers for invoicedate:
jumlah outliers: 0
persentase outliers: 0.00%
lower bound: .2f
upper bound: .2f
min value: .2f
max value: .2f

Outliers for unitprice:
jumlah outliers: 39450
persentase outliers: 7.35%
lower bound: -3.07
upper bound: 8.45
min value: -11062.06
max value: 38970.00
```

2.7.3 Visualisasi Sebelum Handling Outliers

```
fig, axes = plt.subplots(1, 2, figsize=(15, 5))

# Boxplot sebelum handling
axes[0].boxplot(df[col].dropna())
axes[0].set_title(f'Boxplot {col} sebelum handling outlier', fontsize=14, fontweight='bold')
axes[0].set_ylabel('Values')

# Statistik deskriptif
stats_text = f'Mean: {df[col].mean():.2f}\nMedian: {df[col].median():.2f}\nStd Dev: {df[col].st
axes[0].text(1.15, df[col].median(), stats_text, fontsize=10,
             bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.5))
```

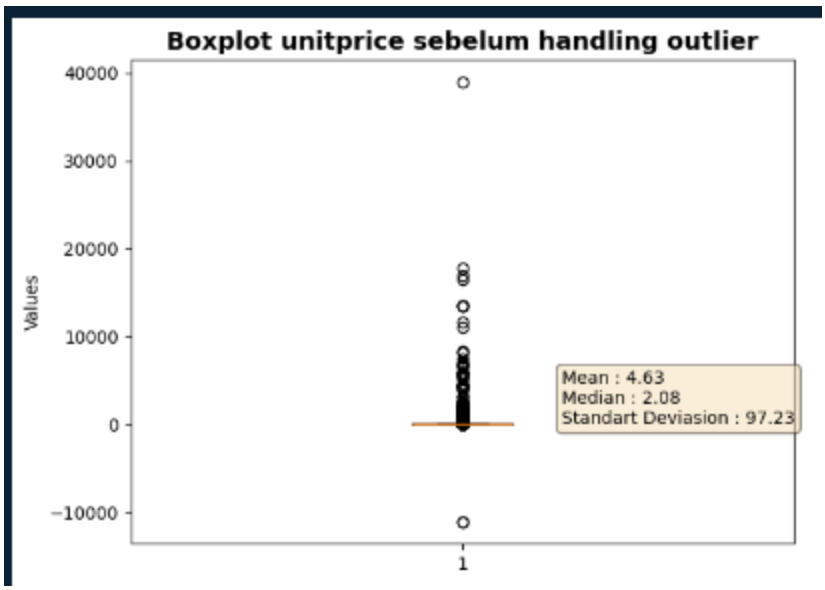

2.7.4 Menghapus Outliers

```
# Menghapus outliers pada kolom 'quantity'
if 'quantity' in df.columns:
    df = df[df['quantity'] > 0]
    print(f"Menghapus data dengan quantity <= 0")

# Menghapus outliers pada kolom 'unitprice'
if 'unitprice' in df.columns:
    df = df[df['unitprice'] > 0]
    print(f"Menghapus data dengan unitprice <= 0")
```

Strategi:

- Menghapus nilai negatif atau nol karena tidak masuk akal dalam konteks bisnis

2.7.5 Visualisasi Setelah Handling Outliers

```
# Boxplot setelah handling
axes[1].boxplot(df[col].dropna())
axes[1].set_title(f'Boxplot {col} (setelah menghapus outliers)', fontsize=14, fontweight='bold')
axes[1].set_ylabel('Values')

# Statistik setelah handling
stats_after = f'Mean: {df[col].mean():.2f}\nMedian: {df[col].median():.2f}\nStd Dev: {df[col].st
axes[1].text(1.15, df[col].median(), stats_after, fontsize=10,
             bbox=dict(boxstyle='round', facecolor='wheat', alpha=0.5))
```

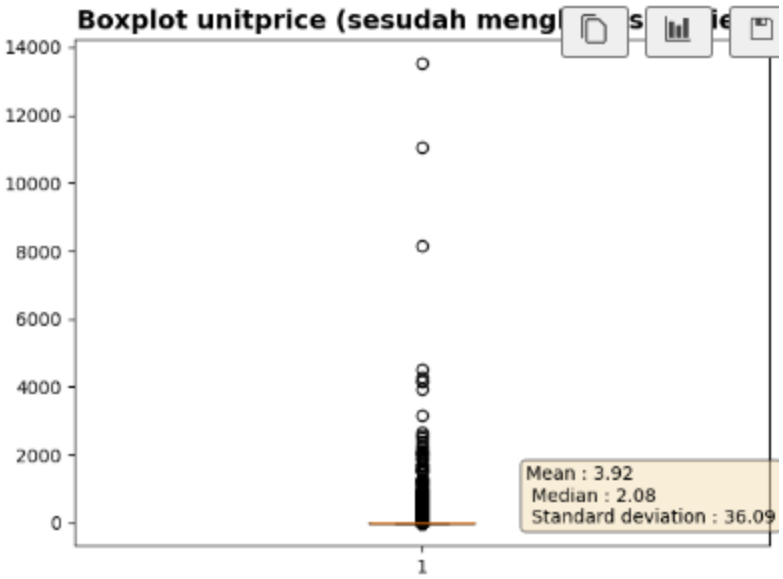

2.8 Create New Features (Feature Engineering)

2.8.1 Membuat Total Price

```
if 'quantity' in df.columns and 'unitprice' in df.columns:
    df['total_price'] = df['quantity'] * df['unitprice']
    print('Kolom total_price berhasil dibuat')
    print(df['total_price'].head())
```

Tujuan:

- Menghitung total harga per transaksi untuk analisis revenue

2.8.2 Extract Fitur dari InvoiceDate

```
if 'invoicedate' in df.columns:
    df['year'] = df['invoicedate'].dt.year
    df['month'] = df['invoicedate'].dt.month
    df['day'] = df['invoicedate'].dt.day
    df['dayofweek'] = df['invoicedate'].dt.dayofweek  # 0=Monday, 6=Sunday
    df['hour'] = df['invoicedate'].dt.hour
    df['weekofyear'] = df['invoicedate'].dt.isocalendar().week
    df['quarter'] = df['invoicedate'].dt.quarter

    # Nama hari dan bulan
    df['dayname'] = df['invoicedate'].dt.day_name()
    df['monthname'] = df['invoicedate'].dt.month_name()
```

Fitur yang Dibuat:

- **Temporal features**: year, month, day, hour, quarter
- **Cyclical features**: dayofweek, weekofyear
- **Categorical**: dayname, monthname

Manfaat:

- Analisis tren temporal
- Identifikasi pola musiman

- Analisis peak hours/days

2.8.3 Kategorisasi Produk dari Deskripsi

```
if 'description' in df.columns:

    def categorize_product(description):
        desc = str(description).lower()

        if any(word in desc for word in ['bag', 'holder', 'storage']):
            return 'bag&storage'
        elif any(word in desc for word in ['light', 'lamp', 'candle']):
            return 'light'
        elif any(word in desc for word in ['paper', 'card', 'notebook']):
            return 'stationary'
        elif any(word in desc for word in ['kitchen', 'cook', 'food']):
            return 'kitchenware'
        elif any(word in desc for word in ['decoration', 'decor', 'ornament']):
            return 'decoration'
        elif any(word in desc for word in ['gift', 'present']):
            return 'gift'
        else:
            return 'others'

    df['category'] = df['description'].apply(categorize_product)
    print(df.columns.tolist())
```

Tujuan:

- Membuat kategori produk dari deskripsi text
- Memudahkan analisis per kategori produk
- Menggunakan **keyword matching** untuk klasifikasi

2.9 Data Quality Report

```
print('=== Data Quality Report After Cleaning ===\n')

# Dimensi data
print(f'Jumlah baris: {df.shape[0]:,}')
print(f'Jumlah kolom: {df.shape[1]}\n')

# Missing values
print('Missing Values:')
print(f'Jumlah missing value: {df.isnull().sum().sum()}\n')

# Duplikat
print('Duplikat:')
print(f'Jumlah duplikat: {df.duplicated().sum()}\n')

# Tipe data
print('Tipe Data:')
for dtype in df.dtypes.unique():
    cols = df.select_dtypes(include=[dtype]).columns.tolist()
    print(f'{dtype}: {len(cols)} kolom')
```

Output:

- Ringkasan kualitas data setelah cleaning
- Verifikasi bahwa tidak ada missing value atau duplikat
- Distribusi tipe data

2.10 Menyimpan Data Cleaned

```
# Menyimpan data yang sudah dibersihkan
df.to_csv('../data/cleaned/ecommerce_cleaned.csv', index=False)
```

Penjelasan:

- `index=False` : Tidak menyimpan index DataFrame sebagai kolom
- Data siap untuk tahap analisis selanjutnya